

Методологический отчёт: спектральная типология МО СЗФО

Источник данных: СберИндекс — расходы муниципальных образований СЗФО, 2023–2024 (условие конкурса).
Проект: спектральная синергетика экономических систем
Объект: 280 муниципальных образований Северо-Западного ФО
Основной метод: медианный threshold по главной моде PLM ($U1 = X \cdot v1$)
Репозиторий: <https://github.com/odisseykingitaki-commits/sber-szfo-spectral>
Воспроизведение: `conda activate sber && python run_all.py` (см. INSTALL.md)
Числа сверены с `results/final_no_income_summary.json`, `results/icvi_full.csv`, `results/variant_c_comparison.json`.

1. Постановка

Нужна устойчивая типология муниципальных образований по структуре потребительских расходов СберИндекса (и смежным признакам), а не простое «разбиение похожих объектов».

Классический KMeans на стандартизованных признаках отвечает на вопрос «похожи ли строки». Нам интереснее: какие направления в пространстве признаков согласованы (спектр оператора зависимостей J), насколько структура «напряжена» (Frustration), и можно ли из главной моды честно получить два читаемых типа поведения расходов.

Основной результат — бипартиция 140 / 140 по медиане проекции на первую моду PLM, $SW \approx 0.346$, с проверками bootstrap / robustness / динамики окон. Сетевой Louvain и KMeans — сравнение, не канон.

2. Данные и признаки

Исходные данные СберИндекс (архивы конкурса)

В финальном расчёте используются оба обязательных zip СберИндекса (`run_all.py` → 01 → 02 → 04). Где это в коде:

#	Архив в data/raw/	Парсер	Используемые поля	Роль в финале
1	potrebitelskie-beznalichnye-rashody-na-urovne-municipalnih-obrazovaniy_ru_1764079373653.csv.zip	src/01_parse_spend.py → spend.parquet	mo, period, category_15, value (2023-01...2024-12)	Основной контур: доли / рост / CV пяти категорий + log_total (16 из 17 признаков)
2	indeks-mobilnosti_ru_1764063764975.csv.zip	src/02_parse_mobility.py → mobility.parquet	ref_area, period, value (даты 2024-12-31, 2025-11-01)	Да, в финале: (а) список МО СЗФО для пересечения с расходами; (б) $mob_logratio = \log1p(d2) - \log1p(d1)$

SHA256 (локальные копии на машине воспроизведения):

- spend: E9A389E57DAD7EC723AC58470FDA2B2F870062A330EFA979CB3952DD7513416D
- mobility: 348B6F58D54D840E417FFAD2ED8F10C3593E70706D8DCBC67D91ABF5F63106F8

Сборка: `src/04_features.py` → `data/processed/features_szfo_v2_final.csv`.

Росстат `urov_2010-2024.xlsx` — не в финальной матрице (только ablation).

Фильтр: пересечение spend ∩ mobility; МО с ≥ 18 месяцев наблюдений и ≥ 6 месяцев в 2024; признаки на базе 2024 (доли/сумма) и 2023–2024 (рост year-mean).

Таблица признаков (p = 17, без income)

Группа	Признаки	Преобразование
Доли категорий	share_health, share_marketplace, share_food, share_grocery, share_transport	доля в «Все категории», 2024
Масштаб	log_total	log1p(total24)
Рост	growth_* (5 категорий)	(mean_2024 - mean_2023) / mean_2023 по месяцам года (если в 2023 ≥ 6 мес.; иначе 0)

Вариативность	cv_* (5 категорий)	σ / μ по месяцам 2024
Мобильность	mob_logratio	$\log_{10}(d_2) - \log_{10}(d_1)$

Порядок столбцов в PLM (как в 05 / 11):

share_health, share_marketplace, share_food, share_grocery, share_transport,
log_total,
growth_health, growth_marketplace, growth_food, growth_grocery, growth_transport,
cv_health, cv_marketplace, cv_food, cv_grocery, cv_transport,
mob_logratio

3. Метод

3.1. Предобработка и бинаризация

- 1 X_raw — матрица N×17.
- 2 X = StandardScaler().fit_transform(X_raw).
- 3 Бинаризация: X_bin = (X > 0).astype(int) — порог ноль *после* z-score (эквивалентно порогу по среднему стандартизованного признака), не медиана сырых значений.

3.2. PLM → спектр J

Для каждого признака j обучается L2-логистическая регрессия остальных на бинарный y_j (C_reg = 0.2, solver lbfgs). Коэффициенты собираются в матрицу, симметризуется: J = (J + J^T)/2, диагональ обнуляется.

Спектр eigh(J), сортировка по убыванию λ. Метрики:

- PR+ — participation ratio положительных мод ≈ 3.44
- Frustration — доля отрицательных λ = 10/17 ≈ 0.59
- λ_max ≈ +5.541; λ_max / Σλ+ ≈ 47.1%

3.3. Основная типология: median threshold

U1 = X · v1
label = 1 if U1 > median(U1) else 0

При чётном N = 280 и отсутствии ties на медиане получается ровно 140 / 140 — by construction. Это канонические метки: results/labels_threshold.npy.

3.4. Два уровня структуры

Жюри может спросить: «где сеть?» — у нас две разные сетевые конструкции, не одна.

Уровень 1 — атрибутивный (сеть признаков)
17 признаков → PLM → матрица J → спектр мод
рёбра связывают ПРИЗНАКИ, не муниципалитеты

Уровень 2 — объектный (сеть муниципалитетов)
МО → проекция на первые 5 мод: U = X · V[:, :5] → ε-граф → Louvain
рёбра связывают МО в пространстве мод

Уровень	Что связано	Артефакт
Атрибутивный	признак ↔ признак	J, спектр, главная мода v1
Объектный	МО ↔ МО	ε-граф, сообщества Louvain

Канон типологии — median threshold на проекции U1 = X · v1 (уровень 1 → разрез объектов).

Louvain — дополнительный сетевой взгляд на близость МО (уровень 2), не замена канона. Оба уровня опираются на одно пространство мод PLM, но отвечают на разные вопросы.

3.5. Сравнение: Louvain (сеть близости МО)

Не основной метод типологии — объектный уровень из §3.4. Строится граф на расстояниях в пространстве проекций на первые 5 мод (U = X · V1-5):

- ε = 40-й квантиль ненулевых расстояний (≈ 3.781);
- рёбер ≈ 15624, узлов 280;
- связные компоненты графа: 3, размеры [278, 1, 1];
- Louvain вызывается на полном графе (не на «главной компоненте»), resolution=0.5, seed=42;
- сырые сообщества: 4, размеры [149, 129, 1, 1];

- после merge сообществ размера $< 10 \rightarrow$ финальные метки [149, 129, 2] (labels_louvain.npy);
- SW Louvain ≈ 0.348 , CH ≈ 80.94 (строка Louvain в icvi_full.csv).

Важно не путать: [278,1,1] — компоненты связности; [149,129,2] — сообщества после склейки малых. Это не «малые компоненты», а малые *сообщества* Louvain.

3.6. Влияние конструкции рёбер (типология vs сеть)

Конкурсный акцент: порог по главной моде и сеть + Louvain отвечают на разные вопросы.

	Threshold (канон)	Louvain (сеть)
Вопрос	как разрезать по оси согласованной структуры признаков	кто близок кому в пространстве мод
Параметр	медиана U1; C_reg	квантиль расстояний $\epsilon(q)$, resolution, min_size
Чувствительность	к C_reg низкая (min ARI ≈ 0.972)	к ϵ высокая: при малых q граф плотнее/связнее; при $q=0.40$ — 3 компоненты
Размеры	140/140 by construction	149/129/2 после merge
SW / CH	SW ≈ 0.346 , CH ≈ 145.2	SW ≈ 0.348 , CH ≈ 80.94

Близость $ARI(\text{threshold}, \text{Louvain}) \approx 0.835$ говорит о согласованности двух взглядов, но не о том, что один метод «доказывает» другой: оба используют одно и то же пространство мод PLM. Выбор ϵ — pragmatic (связный граф на сетке квантилей не получился $\rightarrow q=0.40$). Поэтому канон для типологии — threshold; Louvain оставлен как сетевая карта и проверка согласованности.

3.7. Устойчивость и динамика

- Bootstrap (n=100, ресемпл объектов после scaler на полном N): mean ARI $\approx 0.897 \pm 0.070$.
- Robustness по C_reg in {0.02...2.0}: min ARI ≈ 0.972 (точно 0.97153 vs базовая C=0.2).
- Динамика: скользящие окна 6 месяцев по spend $\rightarrow$ повторная типология; перебежчики $49 / 277 \approx 17.7\%$ хотя бы раз сменили кластер за 19 окон.

3.8. ICVI

Полная таблица: results/icvi_full.csv. Строка threshold (основной метод):

K	SW	CH	S_Dbw	AVI	AVU	MQ
threshold	0.3460	145.25	2.615	0.646	0.657	2.879
Louvain	0.3481	80.94	3.037	0.771	1.629	4.468

4. Спектр и интерпретация мод

Собственные значения $\lambda_1 \dots \lambda_{17}$ (evals_v2.npy), по убыванию:

k	λ_k	k	λ_k
1	+5.541	10	-0.633
2	+2.161	11	-0.866
3	+1.754	12	-1.234
4	+0.908	13	-1.354
5	+0.880	14	-1.479
6	+0.448	15	-1.662
7	+0.075	16	-1.909
8	-0.090	17	-2.339
9	-0.199		

$n+ = 7$; $\Sigma \lambda+ \approx 11.765$; $\lambda_{\max} / \Sigma \lambda+ \approx 47.1\%$.

Мода 1 ($\lambda \approx +5.541$) — ось типологии

Топ-5 по |loading| (evecs_v2.npy):

признак	loading
share_food	+0.391
share_grocery	-0.374


share_transport	+0.334
log_total	+0.327
share_health	+0.279

Интерпретация (паттерн расходов, не юрстатус МО): один полюс тяготеет к более высокой доле общественного питания / транспорта / масштаба расходов, другой — к более высокой доле продовольствия (grocery). Ярлык «городской / сельский» — удобная краткая метка этого контраста.

Моды 2–5 (кратко): вариативность и рост marketplace; рост food / grocery; мобильность vs marketplace; cv_health / grocery — см. results/evecs_v2.npy.


5. Результаты кластеризации

Метрика	Threshold (канон)	Louvain
Размеры	140 / 140	149 / 129 / 2
SW	0.346	0.348
CH	145.25	80.94
ARI vs KMeans (K=2)	0.835	—
ARI threshold↔Louvain	0.835	0.835
Bootstrap ARI	0.897 ± 0.070	—
Robustness min ARI	≈ 0.972	—





Итоговая устойчивость / спектр

Сеть МО СЗФО (eps=3.78, 15624 рёбер)



Сеть Louvain



6. Зачем это практикам

Типология по структуре расходов даёт компактный язык для региональной аналитики: два устойчивых режима потребительского поведения на уровне МО, а не набор разрозненных индикаторов. Для политики и мониторинга это полезно как слой сегментации при сравнении программ поддержки, рискованных зон и эффектов шоков — с оговоркой, что ярлык «город/село» здесь про паттерн трат, а не про административный статус. Устойчивость разреза к регуляризации ($\min \text{ARI} \approx 0.972$) и умеренная доля перебежчиков во времени (~18%) позволяют отличать структурные сдвиги от шума месяца-к-месяцу. Сетевой взгляд (Louvain) дополняет картину близости территорий в пространстве мод, но для операционных дашбордов каноничнее равные классы threshold. Практическая ценность — в воспроизводимом пайплайне: одни и те же признаки → спектр → метки → окна динамики, без ручной подгонки числа кластеров под красивую карту.

7. Сравнение методов и честные ограничения

Сравнение

Метод	Роль	Комментарий
Median threshold U1	основной	типология по главной моде

Louvain	сетевой	согласован ($ARI \approx 0.84$), другой вопрос
KMeans K=2 на X / на модах	baseline	$ARI \approx 0.84$ ожидаем при общей главной оси

Ограничения

- 1 Росстат / доходы — только ablation. В brief часто фигурируют занятость/зарплаты; доступный контур urov в проекте — доходы населения, это не то же самое, что занятость или зарплаты. Добавление income (Variant C OLS-проху для unmatched, в т.ч. районы СПб) не улучшило SW: 0.346 (no-income) vs 0.345 (Variant C), см. results/variant_c_comparison.json. Опциональный код: src/03_parse_urov.py (в run_all оставлен; финальные признаки в 04 всё равно без income).
- 2 Бинаризация $z > 0$; для скошенных признаков доля единиц $\neq 50\%$.
- 3 Мобильность — две даты, грубый mob_logratio.
- 4 Bootstrap: scaler на полном N $\rightarrow$ лёгкий optimism.
- 5 Выборка МО = список мобильности, не полный ОКТМО.
- 6 name_norm: 2 коллизии при внешних join (заполняемый, нарьян-мар).
- 7 ARI vs KMeans при K=2 слабо доказывает «уникальность» PLM.

8. Воспроизводимость

```
conda activate sber
pip install -r requirements.txt
# положить сырые данные в data/raw/ (см. INSTALL.md)
python run_all.py
```

Канон меток: results/labels_threshold.npy.

Сводка: results/final_no_income_summary.json.

Конфиги для жюри (source of truth по параметрам): configs/config.yaml, configs/methods.yaml — скрипты пока дублируют константы; расхождений быть не должно.

Репозиторий: <https://github.com/odisseykingitaki-commits/sber-szfo-spectral>

9. Краткие выводы

- 1 Структура расходов МО СЗФО описывается PLM-спектром с доминирующей модой (~47% положительной массы).
- 2 Каноническая типология — median threshold $\rightarrow$ 140/140, $SW \approx 0.346$, устойчивость по C_reg min $ARI \approx 0.972$.
- 3 Два уровня сети (§3.4): атрибутивный (J) и объектный (ϵ -граф МО); Louvain — согласованный сетевой взгляд ([278, 1, 1] компоненты; после merge [149, 129, 2]), не замена threshold.
- 4 Доходы Росстата не улучшили качество — честный отрицательный ablation.
- 5 Динамика окон показывает живую, но не хаотичную структуру (~18% перебежчиков).