

Методологический отчёт: спектральная типология МО СЗФО

Источник данных: СберИндекс — расходы муниципальных образований СЗФО, 2023–2024 (условие конкурса).

Проект: спектральная синергетика экономических систем

Объект: 280 муниципальных образований Северо-Западного ФО

Основной метод: медианный threshold по главной моде PLM ($u_1 = x @ v_1$)

Репозиторий: <https://github.com/odisseykingitaki-commits/sber-szfo-spectral>

Воспроизведение: `conda activate sber && python run_all.py` (см. INSTALL.md)

Числа сверены с `results/final_no_income_summary.json`, `results/icvi_full.csv`, `results/variant_c_comparison.json`.

1. Постановка

Нужна устойчивая типология муниципальных образований по структуре потребительских расходов (и смежным признакам), а не простое «разбиение похожих объектов».

Классический KMeans на стандартизованных признаках отвечает на вопрос «похожи ли строки». Нам интереснее: какие направления в пространстве признаков согласованы (спектр оператора зависимостей J), насколько структура «напряжена» (Frustration), и можно ли из главной моды честно получить два читаемых типа поведения расходов.

Основной результат — бипартиция 140 / 140 по медиане проекции на первую моду PLM, $SW \approx 0.346$, с проверками bootstrap / robustness / динамики окон. Сетевой Louvain и KMeans — сравнение, не канон.

2. Данные и признаки

Источник	Содержание
СберИндекс (основной)	Расходы МО СЗФО, 2023–2024, категории; выборка МО = покрытие мобильности СЗФО
Мобильность (СберИндекс)	две даты → <code>mob_logratio</code>
Росстат ugov	не в финальной матрице; только ablation (см. § ограничения)

Фильтр: МО с ≥ 18 месяцев наблюдений; признаки на базе 2024 (доли/сумма) и 2023–2024 (рост).

Таблица признаков (p = 17, без income)

Группа	Признаки	Преобразование
Доли категорий	<code>share_health</code> , <code>share_marketplace</code> , <code>share_food</code> , <code>share_grocery</code> , <code>share_transport</code>	доля в «Все категории», 2024
Масштаб	<code>log_total</code>	<code>log1p(total24)</code>
Рост	<code>growth_*</code> (5 категорий)	$(\text{mean last3} - \text{mean first3}) / (\text{first3} + \epsilon)$ по окну года / периоду
Вариативность	<code>cv_*</code> (5 категорий)	σ / μ по месяцам 2024
Мобильность	<code>mob_logratio</code>	<code>log1p(d2) - log1p(d1)</code>

Порядок столбцов в PLM (как в 05 / 11):

`share_health`, `share_marketplace`, `share_food`, `share_grocery`, `share_transport`,
`log_total`,
`growth_health`, `growth_marketplace`, `growth_food`, `growth_grocery`, `growth_transport`,
`cv_health`, `cv_marketplace`, `cv_food`, `cv_grocery`, `cv_transport`,
`mob_logratio`

3. Метод

3.1. Предобработка и бинаризация

- 1 `X_raw` — матрица $N \times 17$.
- 2 `x = StandardScaler().fit_transform(X_raw)`.

3 Бинаризация: `x_bin = (x > 0).astype(int)` — порог ноль *после* z-score (эквивалентно порогу по среднему стандартизованного признака), не медиана сырых значений.

3.2. PLM → спектр J

Для каждого признака j обучается L2-логистическая регрессия остальных на бинарный y_j ($C_reg = 0.2$, solver lbfgs). Коэффициенты собираются в матрицу, симметризуется: $J = (J + J^T)/2$, диагональ обнуляется.

Спектр $\text{eigh}(J)$, сортировка по убыванию λ . Метрики:

- PR — participation ratio положительных мод ≈ 3.44
- Frustration — доля отрицательных $\lambda = 10/17 \approx 0.59$
- $\lambda_{\max} \approx +5.541$; $\lambda_{\max} / \Sigma \lambda \approx 47.1\%$

3.3. Основная типология: median threshold

```
U1 = X @ v1
label = 1 if U1 > median(U1) else 0
```

При чётном $N = 280$ и отсутствии ties на медиане получается ровно $140 / 140$ — by construction. Это канонические метки: `results/labels_threshold.npy`.

3.4. Два уровня структуры

Жюри может спросить: «где сеть?» — у нас две разные сетевые конструкции, не одна.

■■■■■■■■■ 1 - ■■■■■■■■■■■■ (■■■■■ ■■■■■■■■■■)
 17 ■■■■■■■■■■ → PLM → ■■■■■■■■■■ J → ■■■■■■■■■■
 ■■■■■■ ■■■■■■■■■■ ■■■■■■■■■■, ■■ ■■■■■■■■■■■■

[illegible]

Уровень	Что связано	Артефакт
Атрибутивный	признак ↔ признак	J, спектр, главная мода v_1
Объектный	МО ↔ МО	ε-граф, сообщества Louvain

Канон типологии — median threshold на проекции $U_{\square} = X @ v_{\square}$ (уровень 1 → разрез объектов).

Louvain — дополнительный сетевой взгляд на близость МО (уровень 2), не замена канона. Оба уровня опираются на одно пространство мод PLM, но отвечают на разные вопросы.

3.5. Сравнение: Louvain (сеть близости МО)

Не основной метод типологии — объектный уровень из §3.4. Строится граф на расстояниях в пространстве проекций на первые 5 мод ($u = x @ v_{\text{■■■■}}$):

- ε = 40-й квантиль ненулевых расстояний (≈ 3.781);
- рёбер ≈ 15624 , узлов 280;
- связанные компоненты графа: 3, размеры [278, 1, 1];
- Louvain вызывается на полном графе (не на «главной компоненте»), `resolution=0.5`, `seed=42`;
- сырые сообщества: 4, размеры [149, 129, 1, 1];
- после merge сообществ размера $\geq 10 \rightarrow$ финальные метки [149, 129, 2] (`labels_louvain.npy`);
- SW Louvain ≈ 0.348 , CH ≈ 80.94 (строка Louvain в `icvi_full.csv`).

Важно не путать: [278,1,1] — компоненты связности; [149,129,2] — сообщества после склейки малых. Это не «малые компоненты», а малые *сообщества* Louvain.

3.6. Влияние конструкции рёбер (типология vs сеть)

Конкурсный акцент: порог по главной моде и сеть + Louvain отвечают на разные вопросы.

	Threshold (канон)	Louvain (сеть)
Вопрос	как разрезать по оси согласованной структуры признаков	кто близок кому в пространстве мод
Параметр	медиана U1; C_reg	квантиль расстояний $\varepsilon(q)$, resolution, min_size
Чувствительность	к C_reg низкая (min ARI ≈ 0.972)	к ε высокая: при малых q граф плотнее/связнее; при q=0.40 — 3 компоненты

Размеры	140/140 by construction	149/129/2 после merge
SW / CH	SW≈0.346, CH≈145.2	SW≈0.348, CH≈80.94

Близость $ARI(threshold, Louvain) \approx 0.835$ говорит о согласованности двух взглядов, но не о том, что один метод «доказывает» другой: оба используют одно и то же пространство мод PLM. Выбор ε — pragmatic (связный граф на сетке квантилей не получился $\rightarrow q=0.40$). Поэтому канон для типологии — threshold; Louvain оставлен как сетевая карта и проверка согласованности.

3.7. Устойчивость и динамика

- Bootstrap ($n=100$, ресемпл объектов после scaler на полном N): $\text{mean } ARI \approx 0.897 \pm 0.070$.
- Robustness по $C_{reg} \in \{0.02 \dots 2.0\}$: $\text{min } ARI \approx 0.972$ (точно 0.97153 vs базовая $C=0.2$).
- Динамика: скользящие окна 6 месяцев по spend $\rightarrow$ повторная типология; перебежчики 49 / 277 $\approx 17.7\%$ хотя бы раз сменили кластер за 19 окон.

3.8. ICVI

Полная таблица: results/icvi_full.csv. Строка threshold (основной метод):

K	SW	CH	S_Dbw	AVI	AVU	MQ
threshold	0.3460	145.25	2.615	0.646	0.657	2.879
Louvain	0.3481	80.94	3.037	0.771	1.629	4.468

4. Спектр и интерпретация мод

Собственные значения $\lambda_1 \dots \lambda_n$ (evals_v2.npy), по убыванию:

k	λ_k	k	λ_k
1	+5.541	10	-0.633
2	+2.161	11	-0.866
3	+1.754	12	-1.234
4	+0.908	13	-1.354
5	+0.880	14	-1.479
6	+0.448	15	-1.662
7	+0.075	16	-1.909
8	-0.090	17	-2.339
9	-0.199		

$n = 7$; $\Sigma \lambda_k \approx 11.765$; $\lambda_{\max} / \Sigma \lambda_k \approx 47.1\%$.

Мода 1 ($\lambda \approx +5.541$) — ось типологии

Топ-5 по |loading| (evecs_v2.npy):

признак	loading
share_food	+0.391
share_grocery	-0.374
share_transport	+0.334
log_total	+0.327
share_health	+0.279


Интерпретация (паттерн расходов, не юрстатус МО): один полюс тяготеет к более высокой доле общественного питания / транспорта / масштаба расходов, другой — к более высокой доле продовольствия (grocery). Ярлык «городской / сельский» — удобная краткая метка этого контраста.

Моды 2–5 (кратко): вариативность и рост marketplace; рост food / grocery; мобильность vs marketplace; cv_health / grocery — см. results/evecs_v2.npy.

5. Результаты кластеризации


Метрика	Threshold (канон)	Louvain
Размеры	140 / 140	149 / 129 / 2

SW	0.346	0.348
CH	145.25	80.94
ARI vs KMeans (K=2)	0.835	—
ARI threshold↔Louvain	0.835	0.835
Bootstrap ARI	0.897 ± 0.070	—
Robustness min ARI	≈ 0.972	—





Итоговая устойчивость / спектр

Сеть МО СЗФО (eps=3.78, 15624 рёбер)



Сеть Louvain



6. Зачем это практикам

Типология по структуре расходов даёт компактный язык для региональной аналитики: два устойчивых режима потребительского поведения на уровне МО, а не набор разрозненных индикаторов. Для политики и мониторинга это полезно как слой сегментации при сравнении программ поддержки, рисков зон и эффектов шоков — с оговоркой, что ярлык «город/село» здесь про паттерн трат, а не про административный статус. Устойчивость разреза к регуляризации ($\min \text{ARI} \approx 0.972$) и умеренная доля перебежчиков во времени (~18%) позволяют отличать структурные сдвиги от шума месяца-к-месяцу. Сетевой взгляд (Louvain) дополняет картину близости территорий в пространстве мод, но для операционных дашбордов каноничнее равные классы threshold. Практическая ценность — в воспроизводимом пайплайне: одни и те же признаки → спектр → метки → окна динамики, без ручной подгонки числа кластеров под красивую карту.

7. Сравнение методов и честные ограничения

Сравнение

Метод	Роль	Комментарий
Median threshold U1	основной	типология по главной моде

